گزارش پروژه نهایی هوش محاسباتی

نگین حداد(9722762177) – سمیه نیکخو(9722762144)

نیمسال 2 تحصیلی 1401-1400

بخش اول: پیاده سازی کلاسترینگ

روش کلاسترینگ مطابق با مقاله پیوست در فایل زیپ پروژه پیاده سازی شده است. به این صورت که روند اصلی الگوریتم در تابعی به نام clustering پیاده سازی شده است و در خروجی آن لیستی شامل شماره کلاستر است که به شرح زیر میباشد:

```
def clustering(inputs, c_target):
    N = len(inputs)
    d_original(inputs)
    k = 2
    get_R_k(k, N)
    g = 2
    L_array = initial_label(N)
    k_n = initial_k(N)
    s_n = []
    c_previous = N
    c_current = math.floor(N / g)
    D_current_matrix = get_D_current(c_previous, k)
    iteration = 1
    while c_current > c_target:
        print("i = ", iteration)
        s_n = choose_keys_process(D_current_matrix, c_current, s_n, k_n)
        update_labels(L_array, s_n, k_n, D_current_matrix)
        D_current_matrix = update_D_current(c_current, L_array, s_n)
        iteration += 1
        k_n = initial_k(c_current)
        s_n = []
        c_previous = c_current
        c_current = math.floor(c_previous / g)
    s_final = choose_keys_process(D_current_matrix, c_target, s_n, k_n)
```

```
    update_labels(L_array, s_final, k_n, D_current_matrix)
    print("clusters : ", L_array)
```

برای تست مقادیر ثابت زیر در نظر گرفته شده است:

```
k = 2
c_target = 3
g = 2
```

و ورودی و خروجی های تست به شرح زیر است:

تست 1:

ورودی:

```
input_array = [[100], [2], [3], [4], [1560], [1500], [1550], [8], [9], [102]]
```

خروجی:

```
clusters :  [0, 2, 2, 2, 1, 1, 1, 2, 2, 0]
```

تست 2:

ورودی:

```
input_array = [[0, 0], [1, 1], [100, 100], [101, 101], [105, 101],
               [1500, 1400], [1550, 1401], [1500, 1402], [1540, 1200], [1, 2]]
```

خروجی:

```
clusters :  [1, 1, 2, 2, 2, 0, 0, 0, 0, 1]
```

بخش دوم: پیاده سازی الگوریتم Bag Of Words

برای پیاده سازی این الگوریتم ابتدا داده ها را پاک سازی کرده ایم. به این صورت که ابتدا علامت هایی از قبیل نقطه، ویرگول و .. را حذف نمودیم. بعد کامنت ها را lowerCase کرده و سپس stop word ها را از حذف میکنیم. در نهایت ، ریشه کلمات را جایگزین ترکیبات ساخته شده از آن‌ها میکنیم و بدین ترتیب کامنت ها پاک سازی میشوند.

در مرحله بعد، برای کامنت های دیتاست train و test که پاک سازی شده اند مقادیر tf_idf را بدست میاوریم. سپس برای بازنمایی داده ها، این مقادیر را بهSVM میدهیم تا یادگیری روی داده های train انجام گیرد.

در نهایت مقدار accuracy را برای داده های test بدست میاوریم که به شرح زیر خواهد بود:

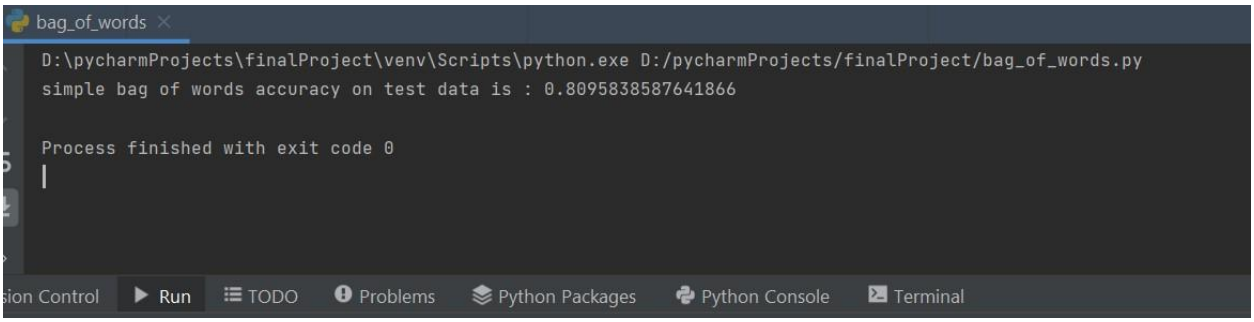

بخش سوم: بهبود الگوریتم Bag Of Word با الگوریتم word2vec

همانطور که در صورت پروژه نیز مطرح گردیده است یکی از مشکلات روش Bag of Words این است که هر کلمه را به طور مجزا در نظر گرفته و ارتباط بین کلماتی که معنی یکسانی دارند را در نظر نمی‌گیرد. در راستای بهبود الگوریتم Bag Of Words ماژولی طراحی نمودیم که این ماژول از مدل word2vec از پیش آموزش دیده شده‌ی -GoogleNews-vectors negative300.bin (لینک دانلود) یک مدل استخراج میکند که یک آرایه از وکتورهایی است که هر وکتور نماینده ی لغات مترادف یک لغت از مجموعه لغات دیتاست میباشد. به این شکل یک دیکشنری در خروجی خواهیم داشت که در هر وکتور آن یک لغت و حداکثر 5 لغت مترادف آن را نگهداری میکند.

در مرحله بعد، در ماژول مربوط به پیاده سازی Bag Of Words پس از آنکه مطابق "بخش دوم" پروژه دیتاست را پاک سازی نمودیم؛ از دیکشنری ساخته شده در مرحله قبل استفاده کرده و به ازای هر لغتی که در کامنت ها وجود دارد، لغت مترادف آن را که در دیکشنری به عنوان سردسته آن مجموعه لغت شناخته میشود را جایگزین میکنیم.

حال یک مجموعه از کامنت های جدید خواهیم داشت که برای آنها مطابق "بخش دوم" پروژه مقادیر tf_idf را بدست میاوریم. سپس برای بازنمایی داده ها، این مقادیر را بهSVM میدهیم تا یادگیری روی داده های train انجام گیرد. و در نهایت مقدار accuracy را برای داده های test بدست میاوریم که به شرح زیر خواهد بود:

```
improved
D:\pycharmProjects\finalProject\venv\Scripts\python.exe D:/pycharmProjects/finalProject/improved.py
improved bag of words accuracy on test data is : 0.832282471626734

Process finished with exit code 0
```

Version Control | Run | TODO | Problems | Python Packages | Python Console | Terminal

واضح است که حدود 3 درصد بهبود در میزان دقت نسبت به حالت قبل داشته‌ایم.

این روش موجب می‌گردد که الگوریتم Bag Of Words بهبود یافته ارتباط لغات مترادف را نیز به نحوی در نظر بگیرد و بدین صورت مقادیر tf_idf نرمالایز شده و بازنمایی دقیق تری از داده های train و test خواهیم داشت . همچنین به تبع accuracy نیز برای دو دیتاست test و train افزایش میابد.